1. Introducción al Deep Learning

Smart City

LAB CTIC UNI

Dr. Manuel Castillo-Cara

Deep Learning con Keras y Python

Web: www.smartcityperu.org

Índice

- Introducción, motivación y enfoque
- Evolución histórica y tendencias
- Conjuntos de entrenamiento, modelos y fiabilidad
- Recursos actuales
- Hacia la estandarización
- Presente y futuro

Smart City

LAB CTIC UNI

Introducción, motivación y enfoque

1. Definición

- Se considera que el término **Deep Learning** fue introducido por primera vez en 1986, pero no ha sido hasta el siglo XXI cuando su uso se ha puesto realmente de moda.
- El principal objetivo del Deep Learning es **emular los enfoques de aprendizaje de los seres humanos**, utilizando para ello una serie de características específicas: transformaciones no lineales, diferentes niveles de abstracción...
- Podemos enfocar el Deep Learning dentro de otros paradigmas de la Ciencia de Datos como una **evolución natural de los mismos**

2. Contexto

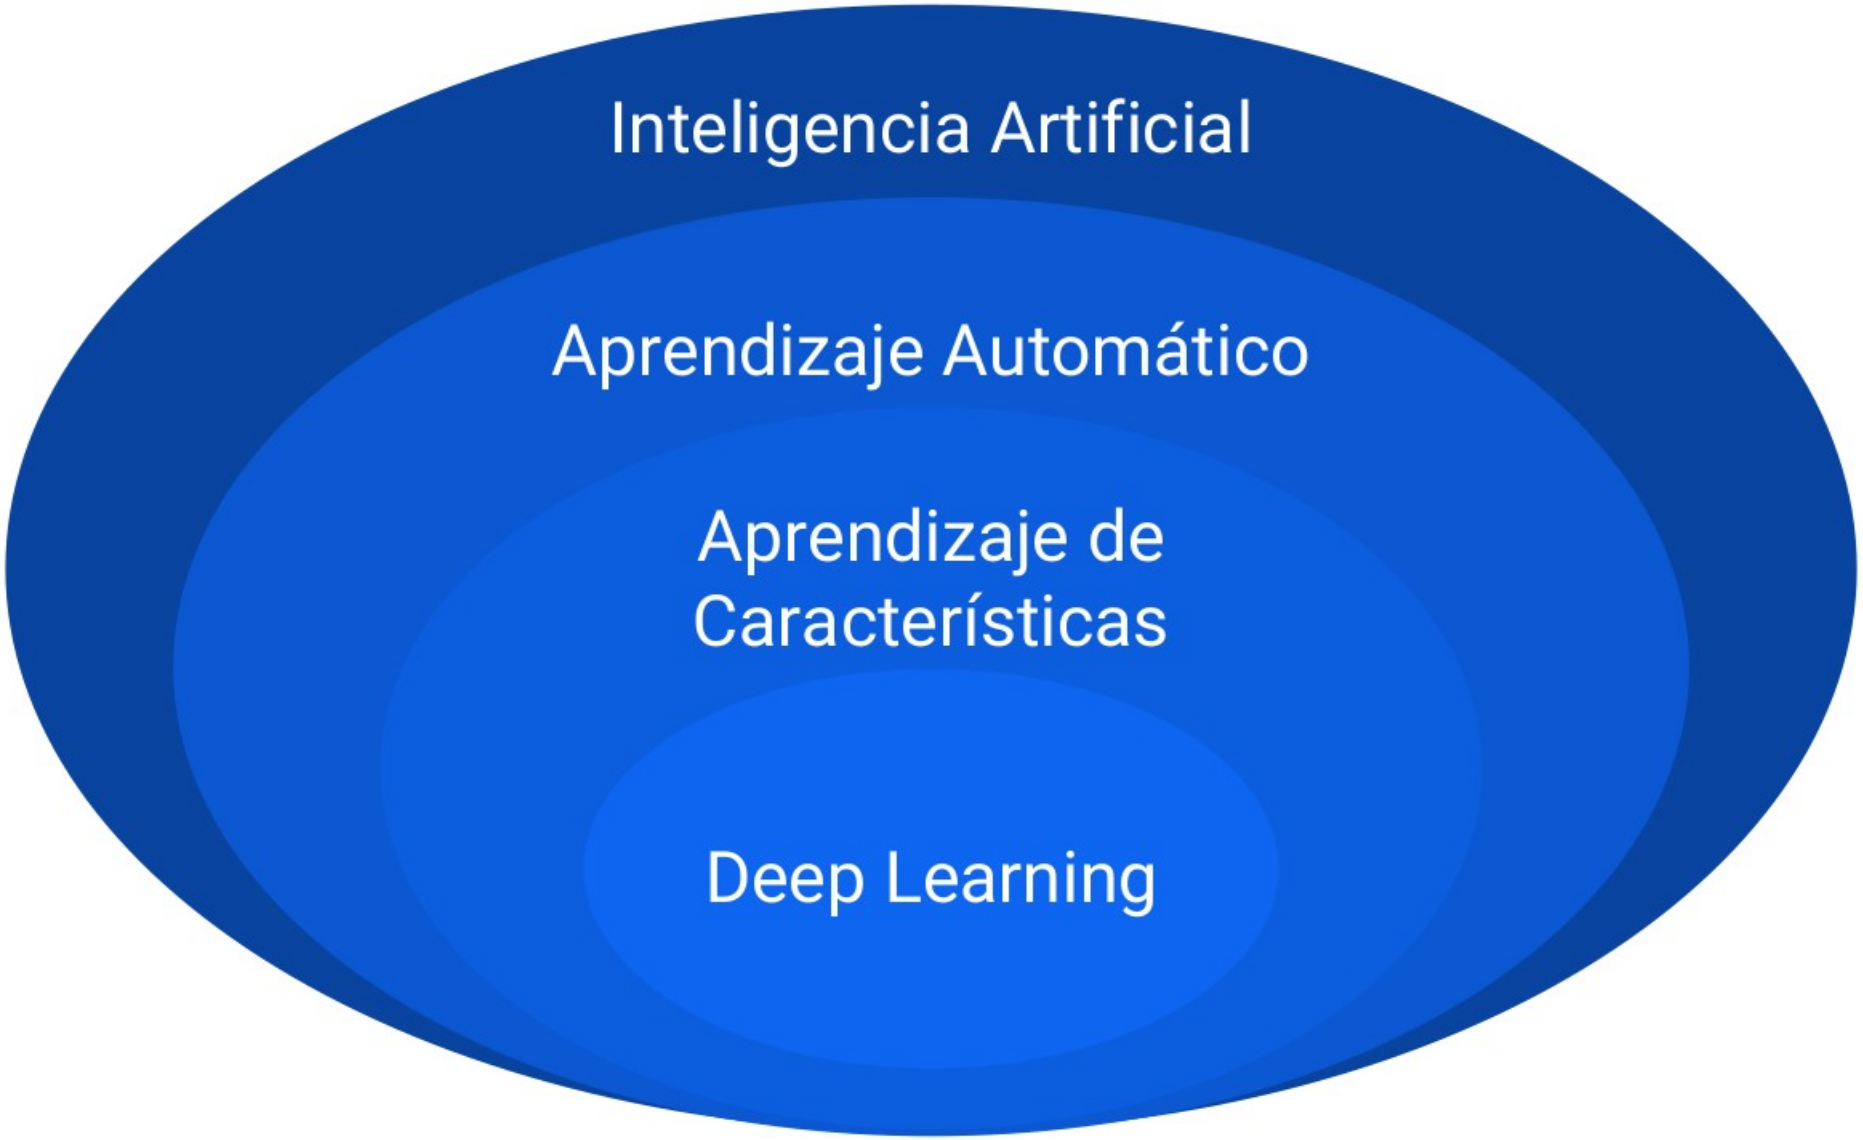
Inteligencia Artificial
Aprendizaje Automático
Aprendizaje de Características
Deep Learning

Smart City

LAB CTIC UNI

Evolución histórica y tendencias

1. Evolución y tendencias (I)

- El inicio del Deep Learning no debe desmarcarse por sí mismo, y podemos considerar su inicio en la **década de los 50**, donde se establecieron algunos paradigmas de la inteligencia artificial
- También se han utilizado otros nombres para referirnos al Deep Learning: ***cybernetics*** en los primero años y ***connectionism*** entre los 80 y 90, coincidiendo en tiempo con diferentes tendencias
- Una de las referencias necesarias para entender la evolución del Deep Learning son las **redes neuronales**, pero con una característica diferenciadora: el uso de los principios del razonamiento humano durante el diseño de los algoritmos

1. Evolución y tendencias (II)

- El primer hito histórico altamente relacionado con el Deep Learning aparece alrededor de 1957, cuando **Frank Rosenblatt** implementa un **perceptrón** capaz de aprender a partir de muestras etiquetadas
- En fechas similares, aparece **ADALINE** (adaptive linear element), que introduce una modificación durante la fase de aprendizaje donde los pesos se ajustan en base a una suma ponderada de los mismos
- El uso de **modelos lineales** por estas soluciones mantenía importantes **limitaciones**, como la famosa incapacidad para representar funciones tipo XOR

1. Evolución y tendencias (III)

- En 1986 aparece un concepto clave para el desarrollo del Deep Learning: **representación distribuida**. En su aplicación a las redes neuronales se promueve un uso más general de las neuronas para que se involucren en la representación de conceptos diferentes
- También en 1986 se populariza el uso del algoritmo ***backpropagation***, el cual amplía su rango de aplicaciones
- El año 2006 se considera esencial para el Deep Learning, dado que Geoffrey Hinton demuestra cómo entrenar correctamente algunas redes para tareas como <u>reducción de dimensionalidad</u> [1].

[1]Hinton, G. E., & Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. science, 313(5786), 504-507

1. Evolución y tendencias (IV)

- El hallazgo de Hinton animó a una comunidad que pronto demostró cómo estos principios también podrían aplicarse para entrenar **otro tipo de redes**
- Desde este momento, el uso del Deep Learning recibe una **gran atención** tanto a nivel práctico como teórico, desarrollándose diferentes teorías sobre la importancia de parámetros internos
- Se puede observar cómo las propuestas basadas en Deep Learning pasan a las primeras posiciones en diferentes **competiciones**... en detrimento de enfoques tradicionales

Smart City

LAB CTIC UNI

Conjuntos de entrenamiento, modelos y fiabilidad

1. Conjuntos de entrenamiento

- Una de las principales razones que **retrasaron el éxito** de modelos basados en Deep Learning fue la baja / nula disponibilidad de conjuntos de entrenamiento **grandes**
- Aquí introducimos el principal requisito de Deep Learning:
  - **Requiere ingentes cantidades de datos** previamente etiquetados para obtener resultados aceptables.
- Las últimas evoluciones no han sido principalmente teóricas, (muchos principios ya se conocían), sino que se deben a la **actual disponibilidad de recursos**:
  - Conjuntos de entrenamiento y también capacidad de computación.

2. Datasets famosos

- 1936 → IRIS flower dataset: 50 muestras (4 características) y 3 categorías
- 1986 → TIMIT speech transcription: 6,300 muestras (texto - transcripción)
- 1987 → STATLOG credits: 690 muestras y 2 categorías
- 1988 → SOYBEAN plants: 307 muestras (35 características) y 19 categs.
- 1998 → MNIST digits: 70,000 muestras (28x28 B/N) y 10 categorías
- 2003 → CALTECH objects: 9,146 muestras (300x200) y 101 categorías
- 2003 → FERET faces: 11,338 muestras y 1,199 categorías
- 2009 → CIFAR 10 objects: 60,000 muestras (32x32) y 10 categorías
- 2014 → IMAGENET objects: 14,197,122 muestras y 20,000 categorías
- 2015 → COCO objects: 2,500,000 muestras y 91 categorías
- 2015 → VIDRILO* rgbd: 22,454 muestras y 25 categorías (15 objetos y 10 habitaciones)

3. Escala temporal

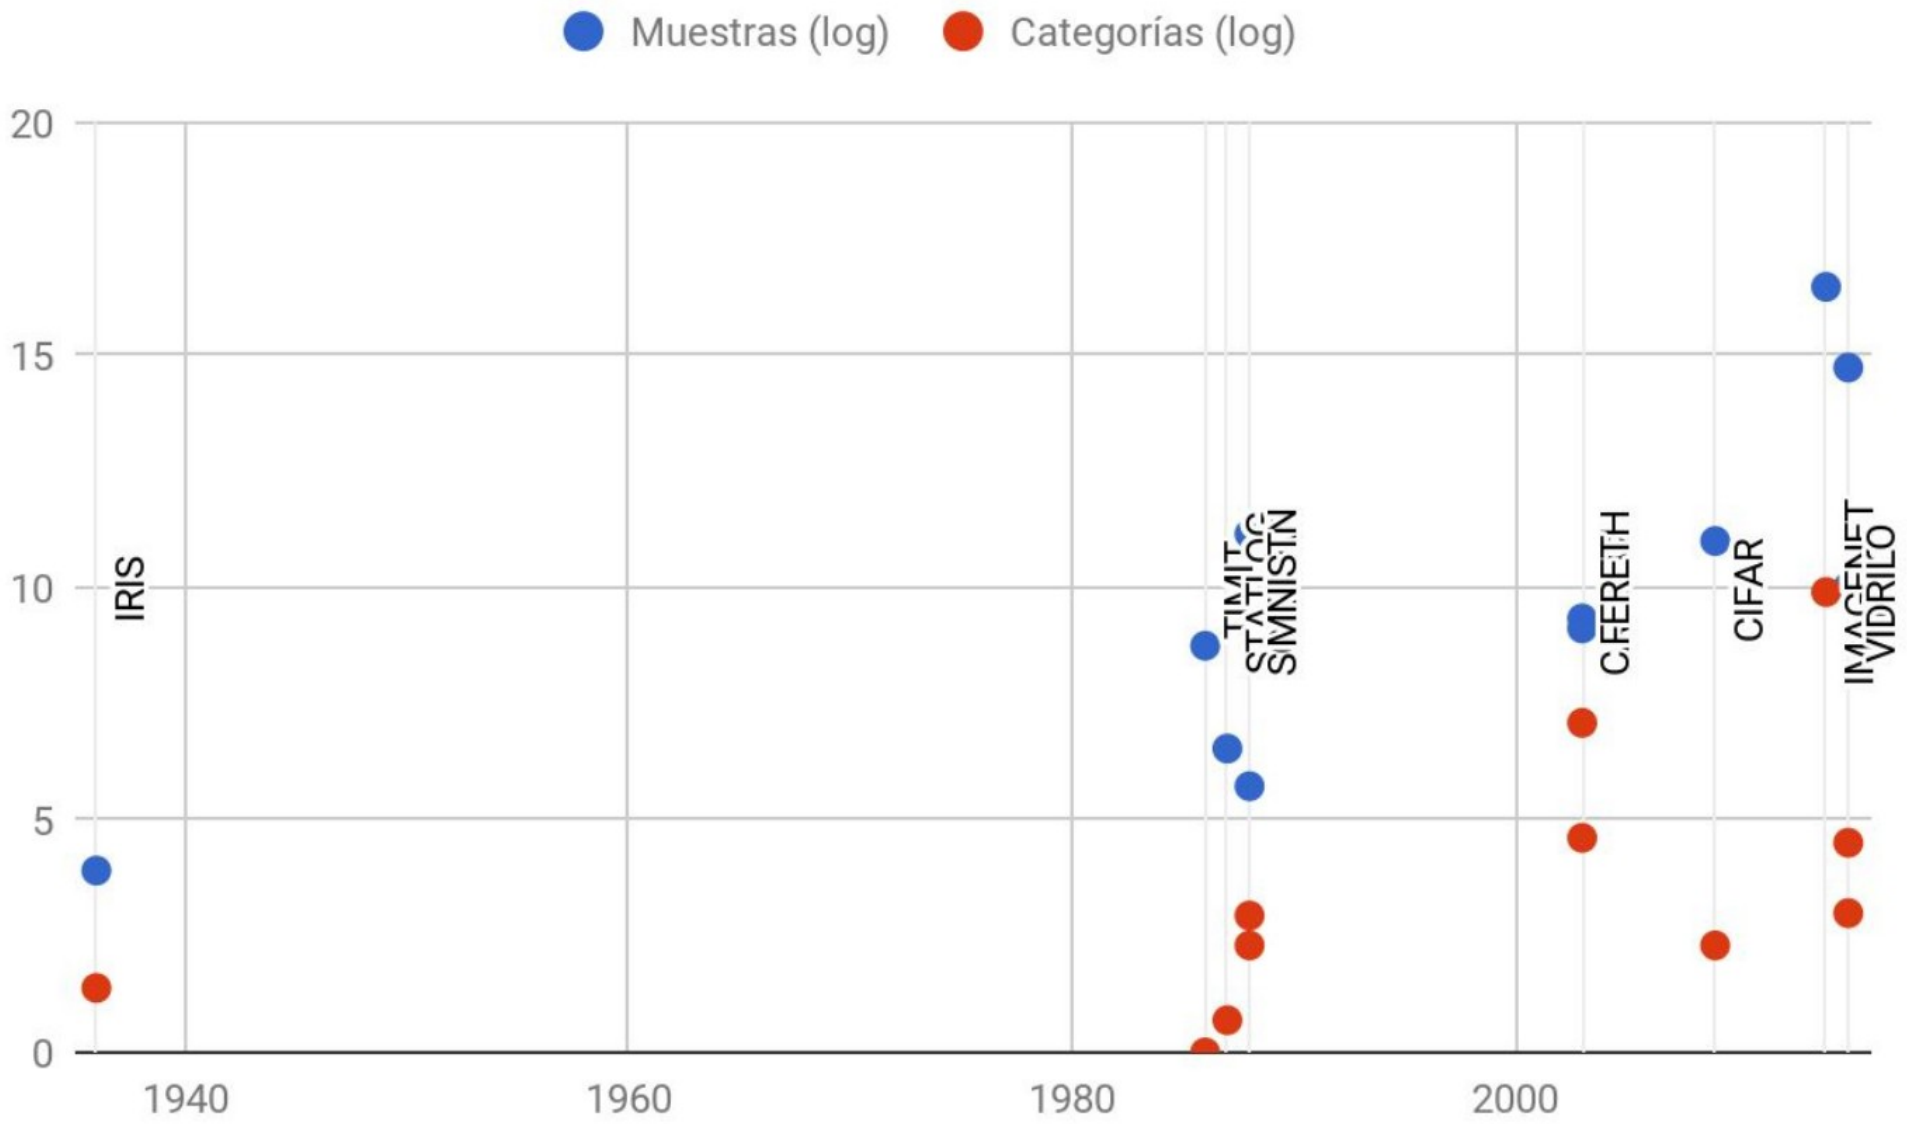

4. Características principales de los datasets

01	Número de muestras	• Más muestras → mayor capacidad para generar modelos más fiables • Aumentan los requisitos computacionales
02	Codificación de las muestras	• Las codificaciones pueden ser directamente capturadas: imágenes, sonidos, textos o requerir cierto procesamiento: características
03	Número de categorías	• Más categorías → mayor complejidad del problema a resolver, pero mayor aplicabilidad (pe: gatos vs perros - raza de perros)

5. Capacidades de computación

- Otro **requisito** para entrenar correctamente soluciones basadas en Deep Learning proviene de las **capacidades de computación**... los modelos poseen un gran tamaño
- El **tamaño** de un modelo de Deep Learning o red neuronal lo determina el **número de capas** intermedias, el número de neuronas de estas capas, y **grado de interconexión** entre neuronas.
- Según las últimas estimaciones, el tamaño de las redes se **dobla cada cerca de 2 años y medio**, y no será hasta 2050 cuando se genere una red con la complejidad del cerebro humano

6. Tamaño de redes neuronales

- Existen dos razones por las que se ha conseguido mantener la tendencia en el aumento del tamaño de las redes neuronales:
  - Disponibilidad de mejores CPUs a precios más asequibles
  - La llegada de las GPUs que permiten realizar operaciones en paralelo de forma más efectiva

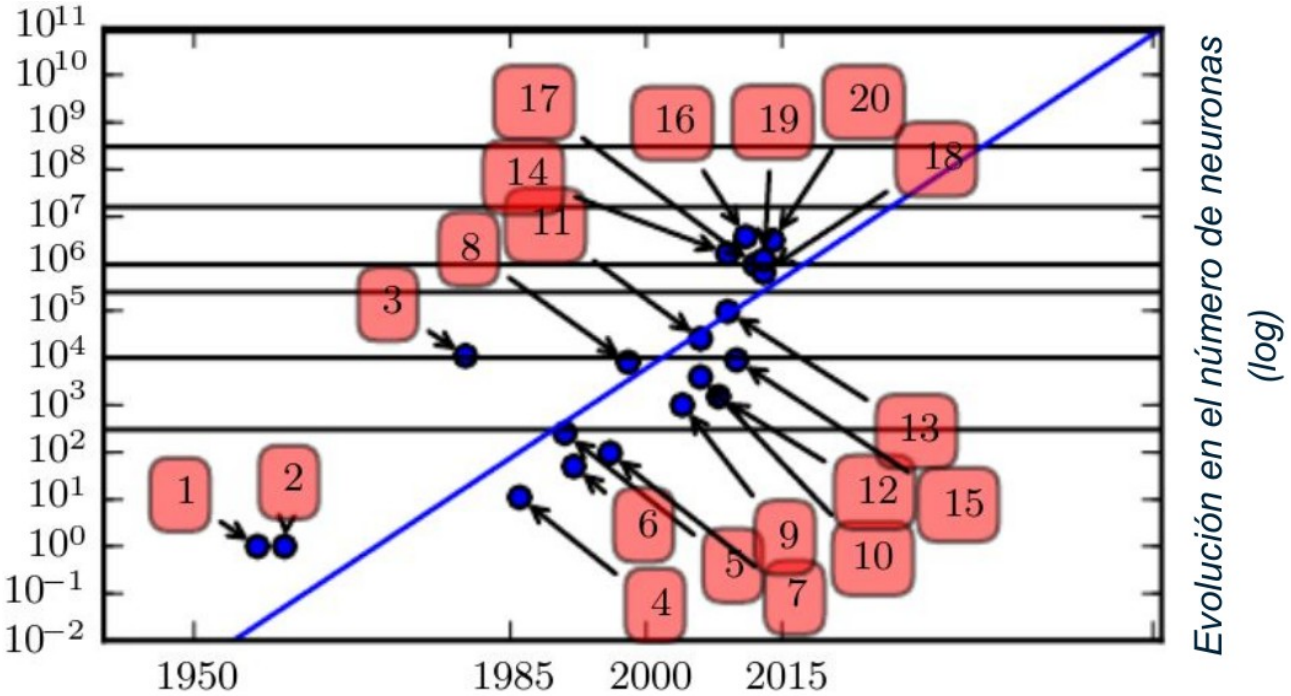

7. GPUs vs CPUs

		Paralelo	Secuencial	
1	GPUs	✓	X	• Más núcleos pero menos potentes • Memoria dedicada
2	CPUs	X	✓	• Menos núcleos pero más potentes • Memoria compartida

8. Competiciones (I)

- La fama del Deep Learning en el mundo de la investigación ha ido ligada al mundo de las **competiciones**, donde cada año se comparan las técnicas propuestas por grupos de investigación de todo el mundo en la resolución de problemas específicos
- Una competición mundialmente famosa es **RoboCup**, donde equipos de robots autónomos juegan al fútbol, pero existen numerosas competiciones en otros ámbitos como el reconocimiento de objetos
- Dentro del reconocimiento de objetos, ha destacado el reto *ImageNet Large Scale Visual Recognition Challenge* (**ILSVRC**), el cual se disputa desde 2010

8. Competiciones (II)

- La mayoría de competiciones establecen normas comunes donde se proporciona a los **participantes** un **conjunto de muestras de entrenamiento** con las que desarrollar las propuestas
  - Tras un determinado periodo, los participantes deben clasificar un conjunto de muestras de test que determinarán su posición en una clasificación final
- **ILSVRC** nació en 2010 como continuación de otro reto, PASCAL VOC, y su objetivo era aumentar la complejidad considerablemente, pasando de 20 a 1000 categorías diferentes
  - Como era de esperar, las primeras ediciones presentaron una gran dificultad con unas tasas de error superiores al 25%

8. Competiciones (III)

- En 2012, sin embargo, hubo una propuesta que redujo el error hasta un 16.4% frente al 25.8% del año anterior. Esta propuesta estaba basada en el uso de redes convolucionales, y el modelo utilizado, **AlexNet**, es ámpliamente conocido
- AlexNet marcó el inicio de sucesivas victorias en diferentes competiciones de propuestas basadas en Deep Learning
- En particular, **ILSVRC** ha sido ganado desde entonces por propuestas basadas en Deep Learning, y su teórica complejidad quedó banalizada en 2015 con una propuesta que obtuvo una tasa de error de sólamente un 3.57%

8. Competiciones (IV)

- La evolución de los modelos que han ganado el reto suele utilizarse como representación en la evolución de la complejidad y fiabilidad de los modelos de Deep Learning en general:

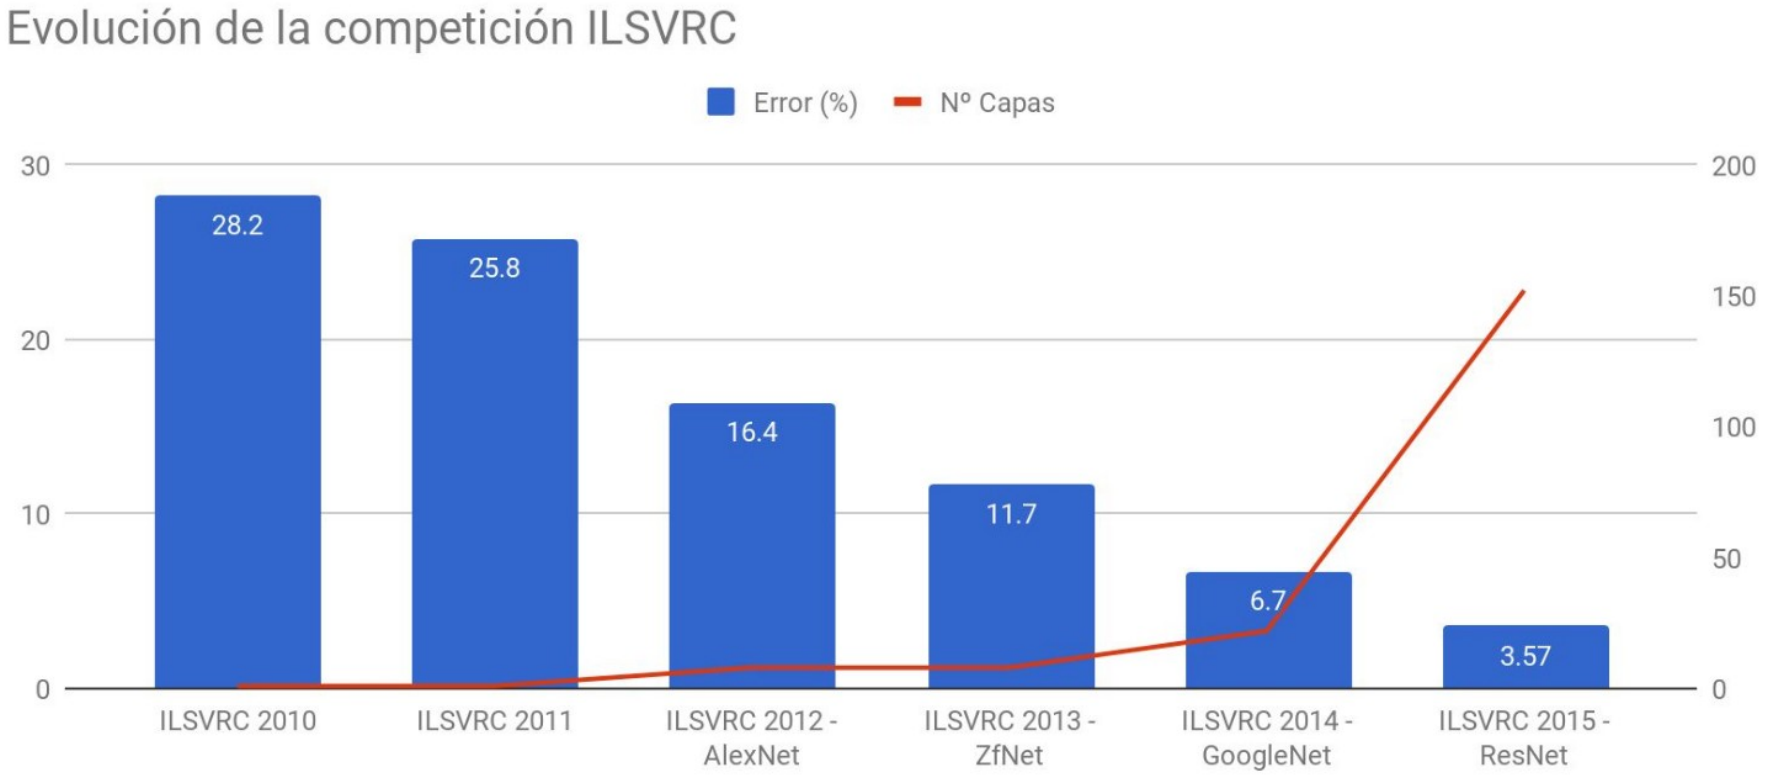

9. AlexNet - 2012

- 5 convoluciones
- 3 capas totalmente conectadas
- 2 normalizaciones y 3 max pool

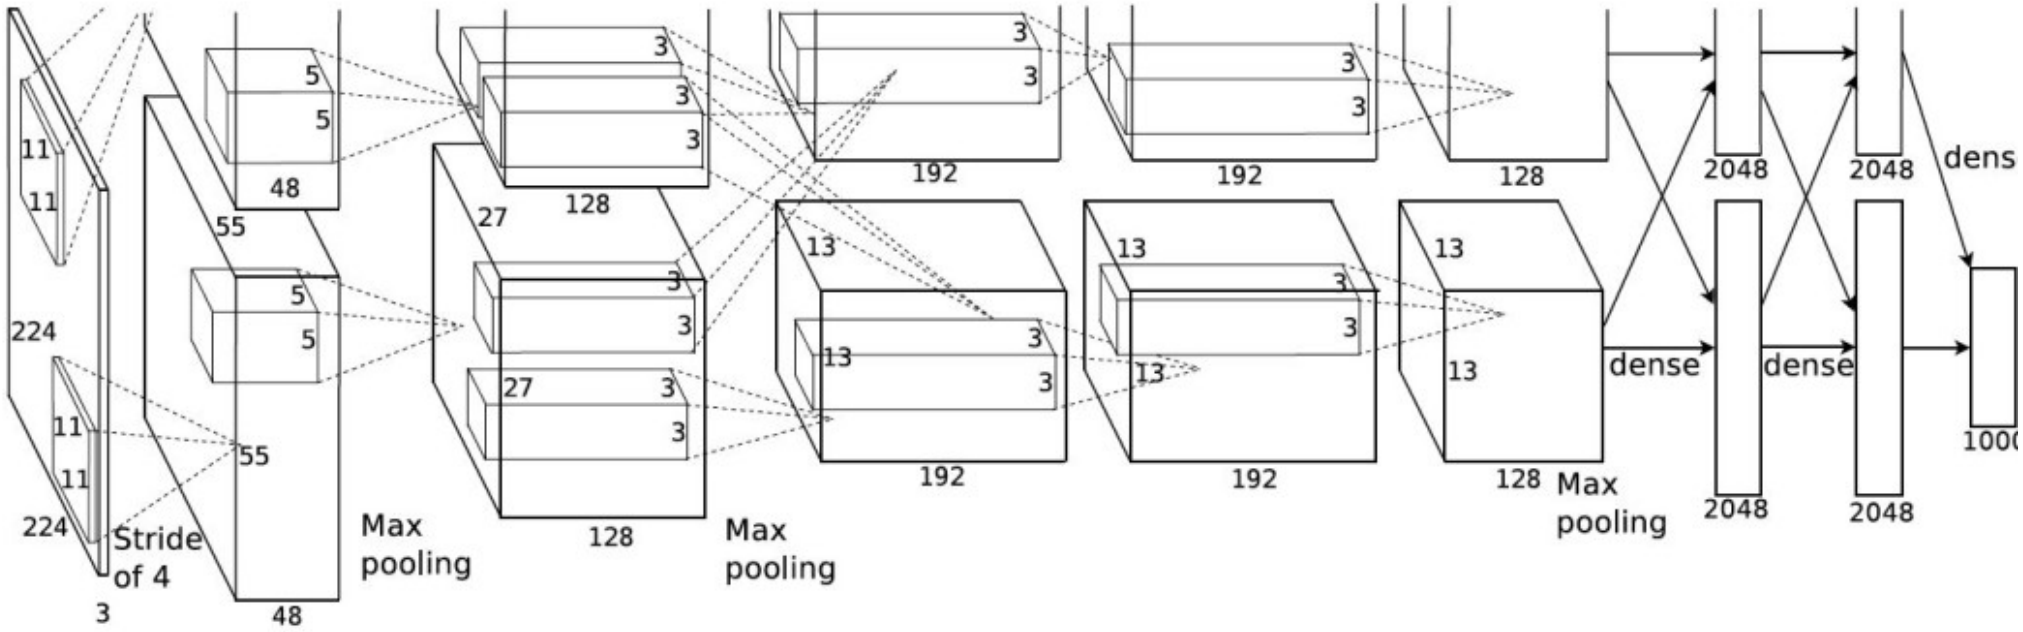

10. ZfNet - 2013

- Cambios en algunos de los parámetros internos

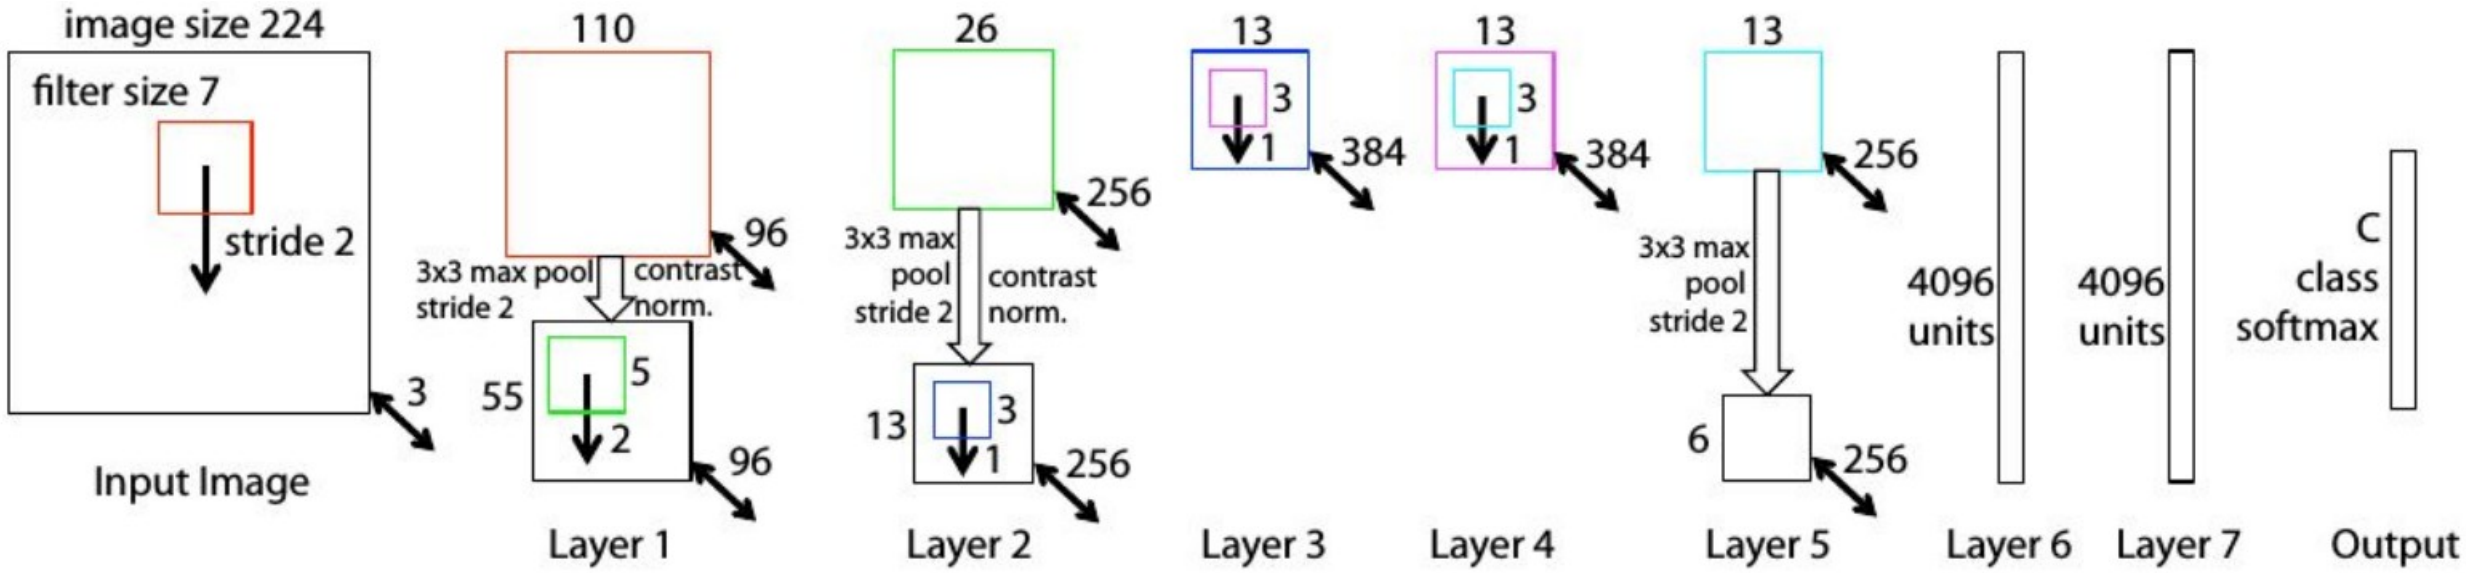

11. GoogleNet - 2014

- Aumenta considerablemente la complejidad de la red
- Introduce un mayor número de capas
- Elimina las capas totalmente conectadas
- Introduce la idea de *inception module* → pequeñas redes dentro de la red

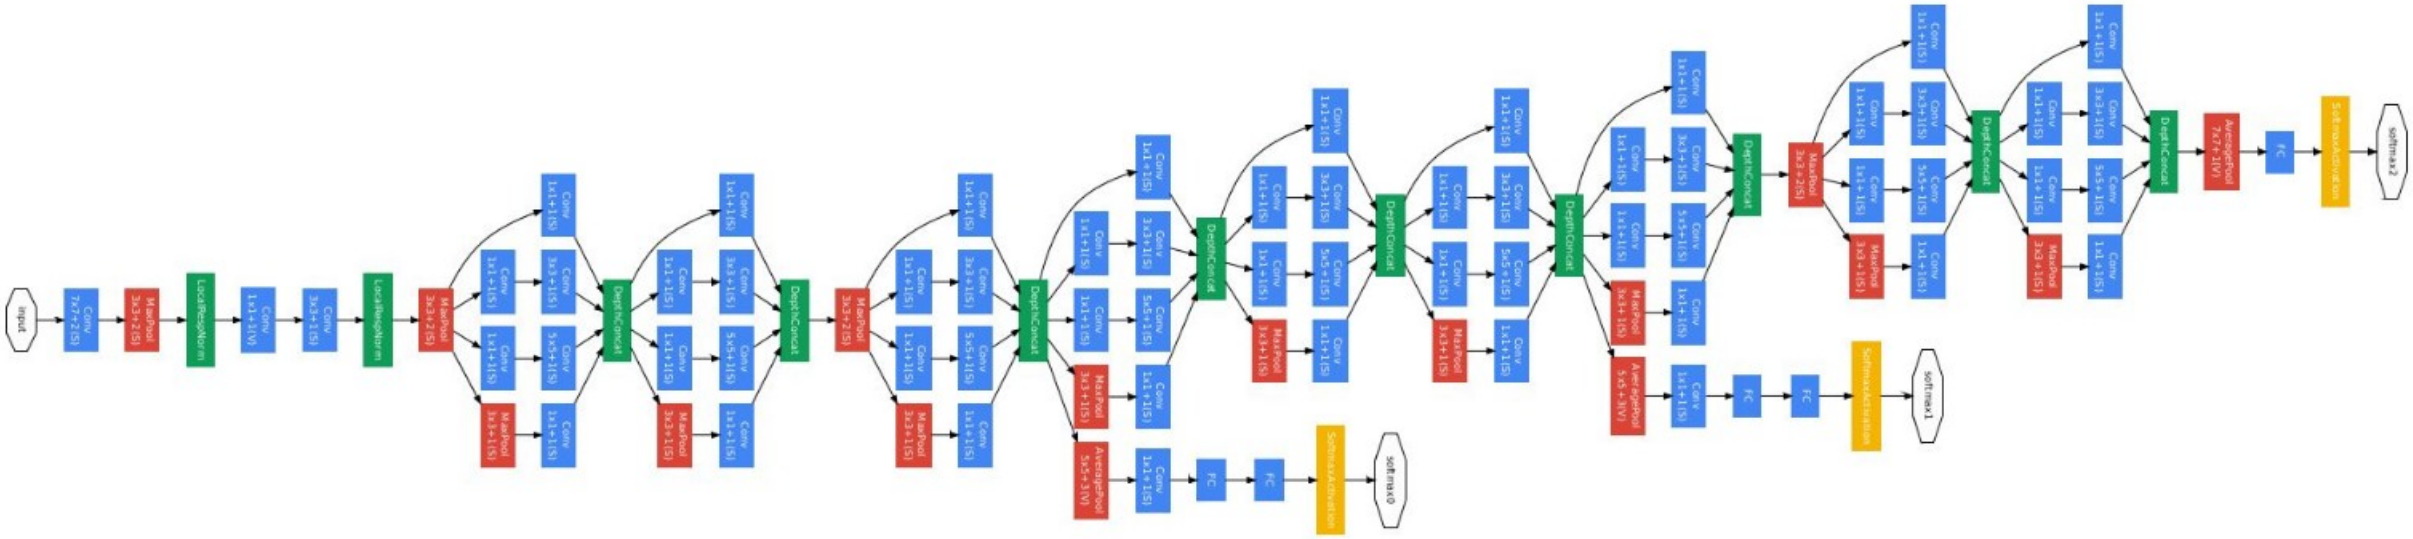
input
Conv 7x7+2(S)
MaxPool 3x3+2(S)
LocalRespNorm
Conv 1x1+1(V)
Conv 3x3+1(S)
LocalRespNorm
MaxPool 3x3+2(S)
Conv 1x1+1(S)
Conv 3x3+1(S)
Conv 5x5+1(S)
MaxPool 3x3+1(S)
Conv 1x1+1(S)
DepthConcat
Conv 1x1+1(S)
Conv 3x3+1(S)
Conv 5x5+1(S)
MaxPool 3x3+1(S)
Conv 1x1+1(S)
DepthConcat
MaxPool 3x3+2(S)
Conv 1x1+1(S)
Conv 3x3+1(S)
Conv 5x5+1(S)
MaxPool 3x3+1(S)
Conv 1x1+1(S)
DepthConcat

12. ResNet - 2015

- La complejidad de la red se dispara hasta las 152 capas internas
- Uso de conectores residuales a través de conexiones

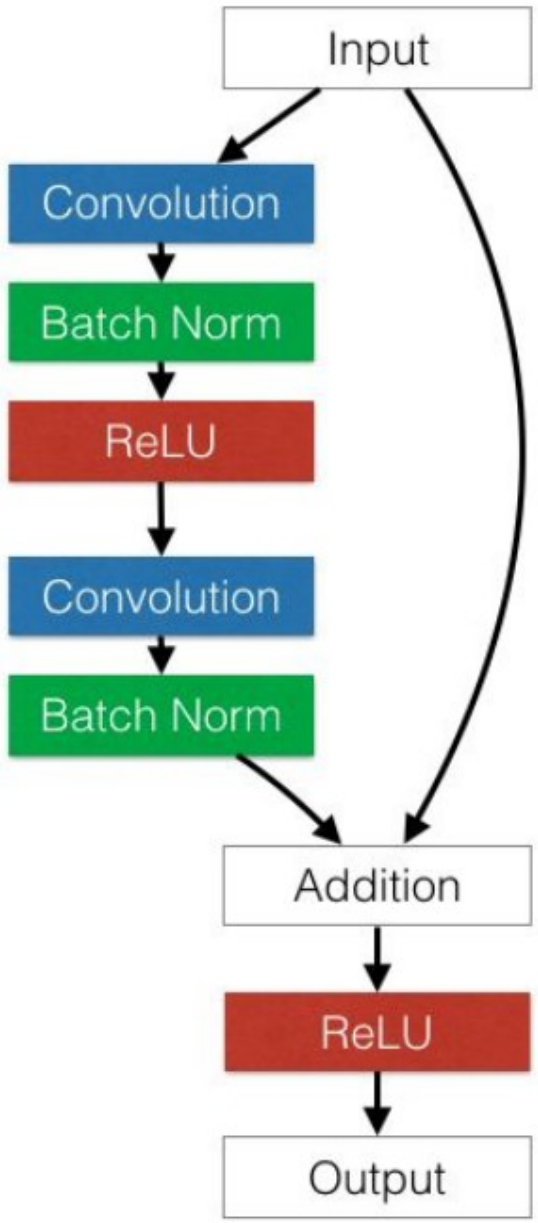

13. Algunas Aplicaciones

- Además de la competición ILSVRC, el uso de Deep Learning también ha conseguido batir las propuestas tradicionales en otros campos

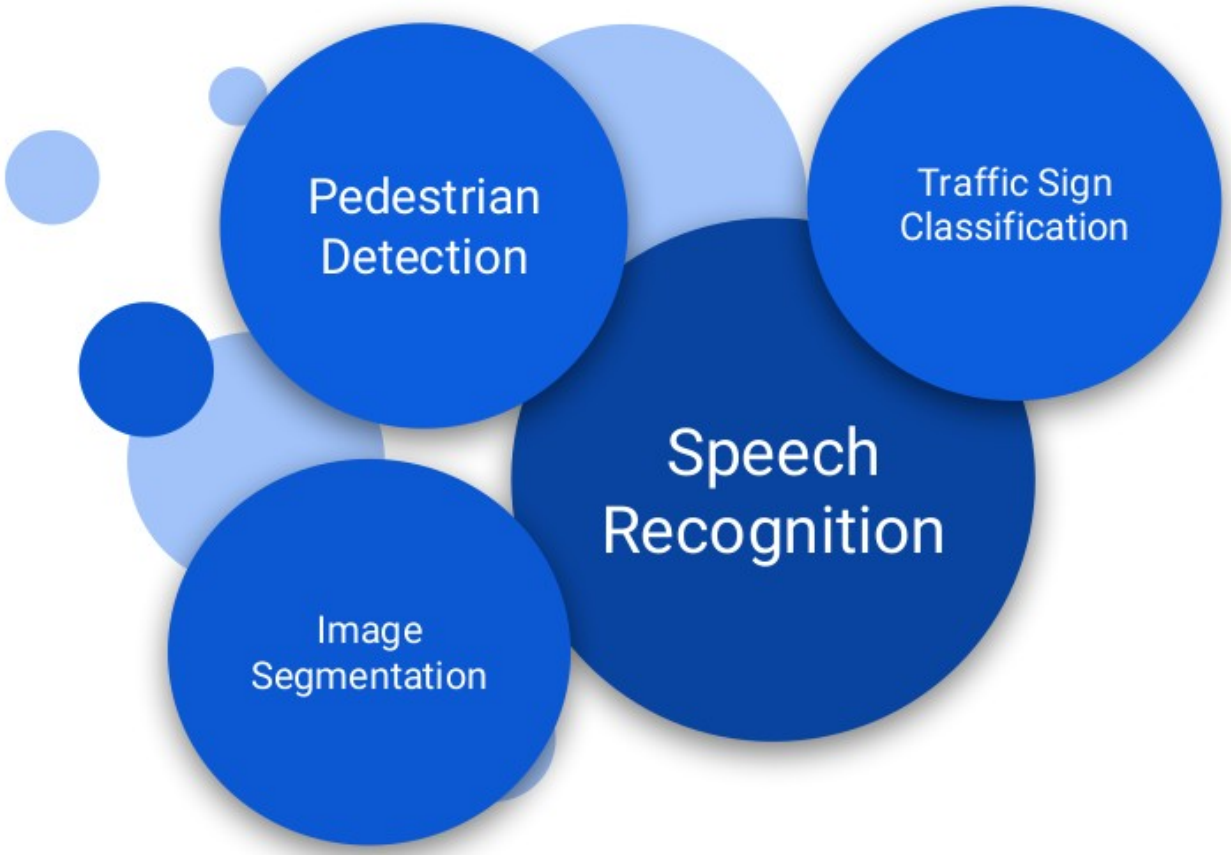

Smart City

LAB CTIC UNI

Recursos actuales

1. Recursos

- Deep Learning se asocia a complejos esquemas con numerosas conexiones **difíciles de implementar**... pero existen recursos que permiten su aplicación sin necesidad de abordar todas las tareas (generación de dataset, diseño, ajustes, entrenamiento)
- 3 **frameworks** gozan de gran popularidad en la actualidad

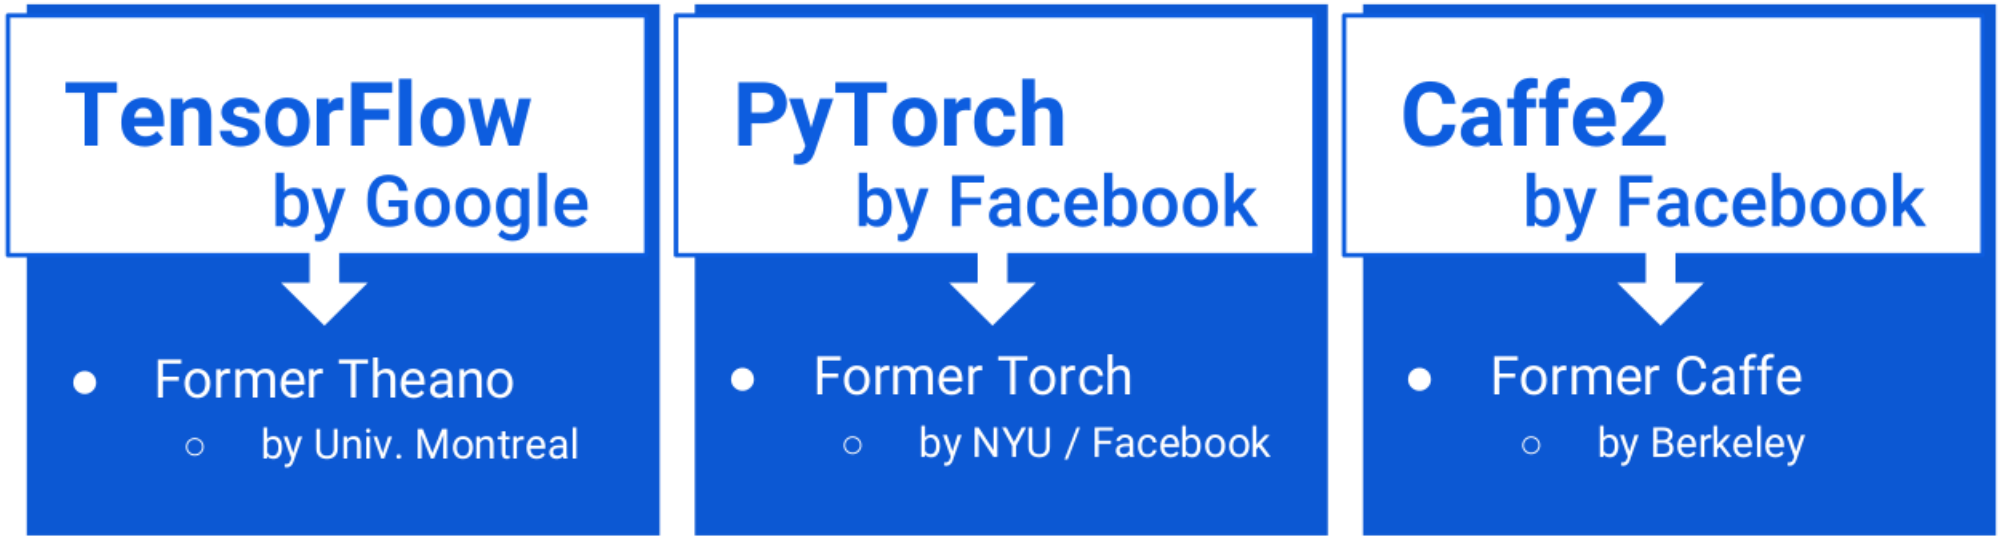

2. Frameworks

Ventajas

- Ejecutar rápida y eficiente los algoritmos tanto sobre **GPUs** como **CPUs**
- Realizar fácilmente **complejos cálculos esenciales**, como los gradientes de las redes (derivadas parciales)
- **Diseñar** sin problemas grandes redes
- Contar con una **comunidad** y **documentación** para la realización de numerosos ejemplos que sirvan de base

2. Frameworks
Caffe2 by Facebook

- APIs en dos lenguajes: C++ y Python
- Multiplataforma: Windows, Ubuntu, Mac
- Fácil instalación a través de ANACONDA
- Características diferenciadoras frente a otros frameworks:
  - Modularidad
  - Diseño enfocado a la escalabilidad y su **uso en dispositivos móviles**
- Permite transformar modelos desde Torch o Caffe
- Implementación GPU basada en CUDA
- Enfocado a entornos de producción → como su uso en Android

2. Frameworks
PyTorch by Facebook

- Python (también C++)
- Paquete de Python ampliable
- Windows, Ubuntu y Mac
- Fácil instalación a través de ANACONDA
- Enfocado a entornos de desarrollo e investigación

  → mayor flexibilidad
- Términos clave: tensores, variables, y módulos
- Paquete especializado en visión: **torchvision**

  → carga automática de imágenes de datasets estándar como MNIST

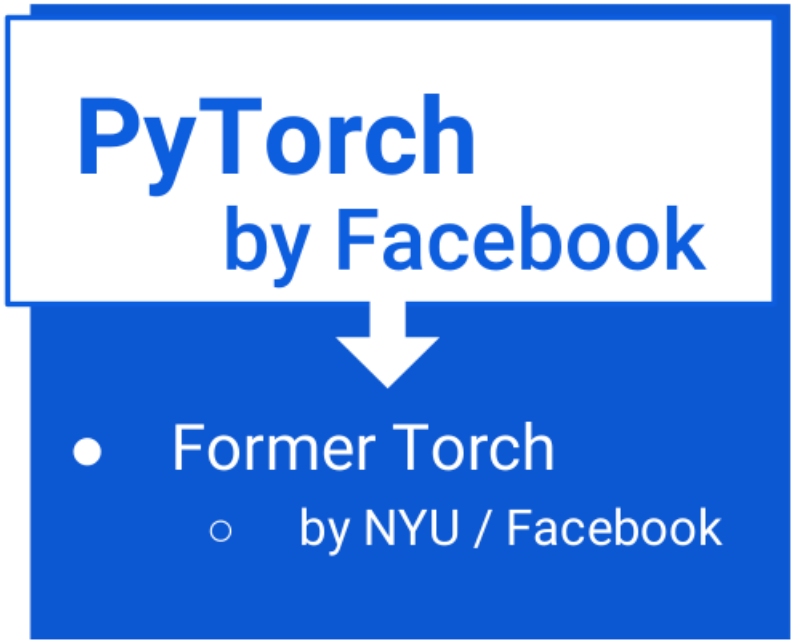

2. Frameworks
TensorFlow by Google

- Python, pero con APIS para Java, C y Go
- Multiplataforma: Windows, Ubuntu, Mac
- Fácil instalación a través de ANACONDA, Docker, repos...
- Es el entorno que utilizaremos en las prácticas

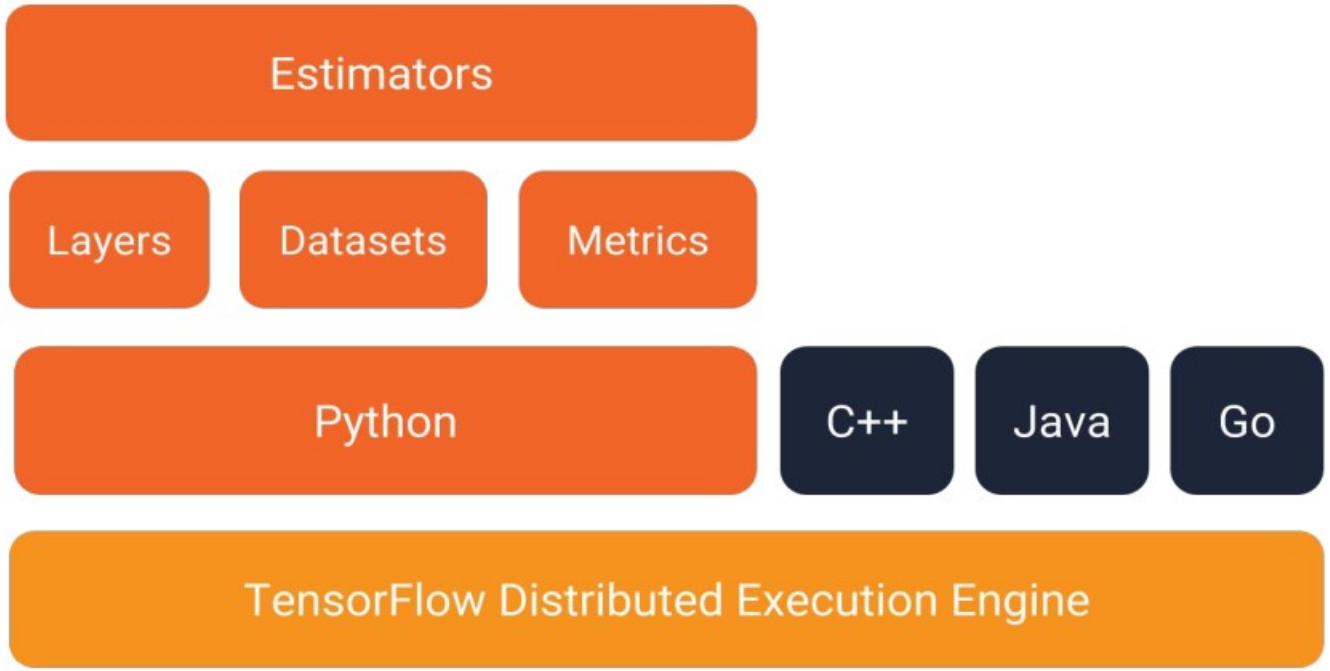

3. Otros Frameworks

- Además de los frameworks ya destacados, debemos mencionar otras alternativas como Apache MXNet o Microsoft Cognitive Toolkit
- También destacamos el uso de **Keras**, una librería modular que puede integrarse con algunos de los frameworks actuales y que proporciona facilidades para prototipar rápidamente soluciones de deep learning usando diferentes tipos de redes, ejecutándose en CPU o GPU

4. Datasets

- El uso de datasets estándar nos permite comparar los resultados obtenidos frente a otras técnicas

  → Evita la tarea de tener que **etiquetar** las muestras

- Muchos de los datasets se encuentran **ya integrados** dentro de los frameworks de Deep Learning, de forma que su uso se facilita ampliamente.
- Algunos datasets de referencia.
  - Iris: 150 muestras (5 características numéricas) y 3 categorías
  - MNIST: 60,000 muestras (28x28) y 10 categorías
  - CIFAR-100: 60,000 muestras (32x32) y 10 categorías

Smart City

LAB CTIC UNI

Hacia la estandarización

1. Contexto

- Durante muchos años, el Deep Learning únicamente era accesible para desarrolladores con **grandes conocimientos de aprendizaje automático y capacidad de computación**
- Desde 2013 han aparecido diferentes **plataformas** donde se ofrecían **modelos ya entrenados** que proporcionan etiquetas a partir de imágenes.
  - Esto ha marcado la línea hacia la **estandarización**, facilitando la reutilización de recursos
- **Clarifai** fue una de las primeras apuestas comerciales para sistemas de etiquetado tras su experiencia en el reto ILRSCV

1. Contexto
Clarifi

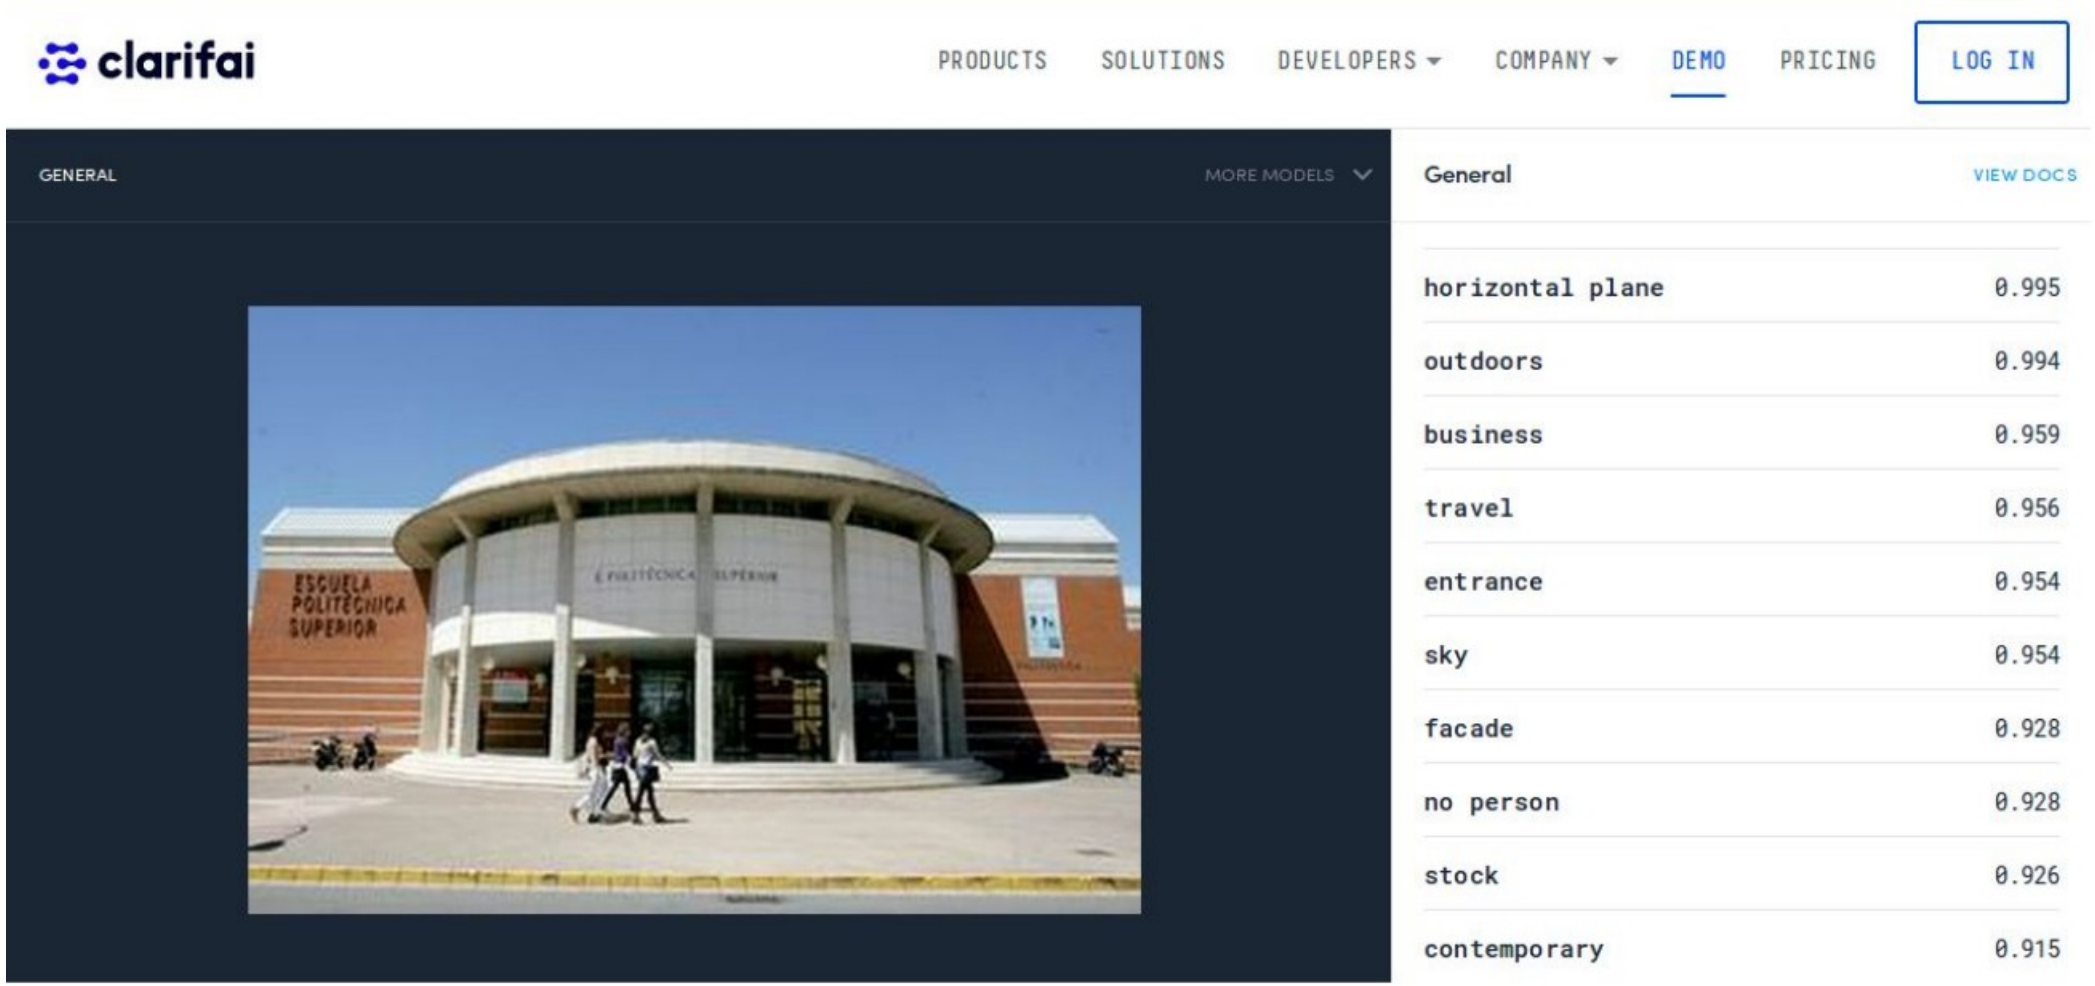

2. Reutilización de modelos (I)

- Dentro de las apuestas por la reutilización de modelos, el framework Caffe logró poner a **disposición de la comunidad** numerosos modelos utilizando para ello la plataforma Zoo
- Podemos definir los modelos como la combinación de una **arquitectura de red** (número y tipo de capas) y sus **pesos** asociados para la realización de clasificaciones.
- Estos han permitido su uso tanto como aprovechamiento directo **a través de APIs**, como punto de entrada para evitar partir de 0 a la hora de desarrollar un modelo.

2. Reutilización de modelos (I)

- Utilizando modelos ya generados, podemos **aprovechar** el conocimiento codificado en redes neuronales sin la necesidad de poseer los **recursos necesarios** para su entrenamiento.
- También evita comenzar desarrollos desde 0, de forma que se pueda **partir de una red** que quizá haya encontrado una codificación óptima para la mayoría de imágenes, pero que no distinga bien entre categorías específicas.
- Además de Zoo (Caffe / Caffe2), el resto de frameworks también está **apostando** para el almacenamiento y **reutilización** de modelos ya entrenados.

Smart City

LAB CTIC UNI

Presente y Futuro

1. Contexto

- Además de los frameworks, datasets, o modelos ya entrenados, existen numerosos recursos que han cambiado las posibilidades actuales (y puede que futuras) del Deep Learning
- Uno de ellos es la existencia de numerosas **APIs** que permiten funcionalidades, sobre todo enfocadas al reconocimiento de imágenes, gracias al uso interno de Deep Learning
- Gracias a estas APIs, podemos complementar cualquier imagen capturada con **información adicional** en dispositivos de bajo poder computacional

2. APIs basadas en Deep Learning

- IBM Watson → reconocimiento de imágenes y traducción automática
- Google Prediction → procesamiento del lenguaje natural, predicción, reconocimiento de patrones, etc.
- AT&T Speech → procesamiento del lenguaje natural
- Wit.ai → text to speech
- Amazon Rekognition → procesamiento de imágenes y vídeos
- Diffbot → obtener información de webs a a partir de sus textos, imágenes y comentarios
- AlchemyAPI → numerosas soluciones de aprendizaje automático incluyendo visión, procesamiento del lenguaje natural, o sentiment analysis

3. AWS Deep Lens

- Una de las apuestas más arriesgadas por el Deep Learning por parte de Amazon es AWS DeepLens, un dispositivo con cámara capaz de ejecutar en local diferentes algoritmos
  - Precio: 249$
- Esta cámara permite descargar modelos ya entrenados o desarrollar proyectos propios
- Totalmente integrada con los servicios de AWS
- Procesador Intel Atom 5Ghz, 8 Gb RAM, Ubuntu 16.04 LTS, Motor para gráficos Intel Gen9

4. Intel Movidius

- Intel ha lanzado un memory Stick que proporciona unas altas capacidades de desarrollo de algoritmos basados en Deep Learning gracias a un procesamiento dedicado integrable en cualquier sistema

  → Precio estimado: 99,78 €

- Permite adaptar modelos de Caffe para su ejecución en tiempo real

5. AIY

- Destacamos algunos kits que permiten construir dispositivos de IoT a un bajo coste, y sobre los cuales implementar soluciones
- Proyecto AIY: usando componentes básicos y una Raspberry
  - Zero permite construir soluciones de **visión** y **sonido/voz**
  - Do-it-yourself artificial intelligence
  - https://aiyprojects.withgoogle.com/

¡GRACIAS!

Smart City

LAB CTIC UNI

Dr. Manuel Castillo-Cara

Deep Learning con Keras y Python

Web: www.smartcityperu.org